



PluriTAL

Analyse statistique des données textuelles

2025-2026 (M1)

Groupe 8 (Chinois)

Les commentaires en ligne sur

les sites de e-commerce

Enseignant encadrant : Mathieu Valette

Etudiant.e.s : Emmy Le bail, Mengge Liu, Peng Chen, Ting Zheng, Shiyi Yao

SOMMAIRE

1. Introduction.....	2
2. Présentation du corpus.....	2
2.1. Corpus humain.....	2
2.2. Corpus AI.....	2
3. Analyses Statistiques.....	3
3.1. Factorielle des correspondances.....	3
3.2. Spécificités lexicales.....	4
3.3. Concordances.....	5
3.4. Cooccurrences.....	6
4. Bilan des analyses.....	7
5. Annexes.....	8
5.1. Statistiques générales du corpus initial.....	8
5.2. Prompts pour la génération du corpus IA.....	9
5.3. Top 50 des mots spécifiques par sous-corpus.....	10
5.4. Exemples de concordances des mots spécifiques.....	12
5.5. Analyse des cooccurrences de termes spécifiques : 酒店/ hôtel	17
5.5.1. POS.....	17
5.5.2. NEG.....	18

1. Introduction

Notre projet porte sur les commentaires en ligne en chinois, plus précisément sur les avis d'hôtels. Ce domaine nous semble pertinent car les avis jouent un rôle important dans les décisions de réservation : les utilisateurs s'appuient souvent sur les expériences d'autres clients pour évaluer la propreté, le service, l'emplacement ou le rapport qualité-prix d'un hôtel. Avec le développement des modèles d'IA générative, il devient cependant plus difficile de distinguer les avis authentiques des commentaires produits automatiquement.

La problématique de notre travail est donc la suivante : comment identifier les caractéristiques des commentaires générés par l'IA afin de les distinguer des avis humains ?

Nous faisons l'hypothèse que les avis IA présentent des formulations plus régulières et plus standardisées, tandis que les avis humains contiennent davantage de marques personnelles, d'oralité, d'irrégularités et de détails liés à une expérience réelle.

2. Présentation du corpus

Notre travail s'appuie sur deux types de corpus : un corpus humain et un corpus généré par des LLMs. Les deux corpus sont construits à partir d'un corpus initial de commentaires chinois issus du site [JD](#) (*site chinois de commerce en ligne*). Ces commentaires ont été collectés en 2016, à une période où les outils d'IA générative n'étaient pas encore largement utilisés. Le corpus initial contient 62,773 commentaires, répartis en 10 catégories (ex : *livre, fruit, vêtement, hôtel* etc), pour un total de 2,359,952 tokens. (*une présentation détaillée de ce corpus est disponible dans l'Annexe 4.1*)

2.1. Corpus humain

Après l'observation du corpus initial, nous avons choisi de nous concentrer sur une seule catégorie : hôtel. Cette catégorie contient suffisamment de données pour construire des sous-corpus équilibrés. De plus, notre objectif principal n'est pas de comparer plusieurs types de produits, mais d'analyser les différences entre avis positifs et négatifs, ainsi qu'entre commentaires humains et commentaires générés par différents modèles d'IA. Afin de garder un corpus équilibré, nous avons construit deux fichiers d'environ 125,000 tokens chacun :

`HUM_cat-hotel_pol-POS.txt` : avis humains positifs (*125501 tokens*)

`HUM_cat-hotel_pol-NEG.txt` : avis humains négatifs (*125243 tokens*)

2.2. Corpus AI

Le corpus IA a été construit à partir de commentaires d'hôtels générés par deux LLMs : GPT et DeepSeek. Pour chaque modèle, nous avons généré des avis positifs et des avis négatifs, afin de pouvoir les comparer avec les sous-corpus humains correspondants.

Pour obtenir des commentaires variés, nous avons utilisé plusieurs types de prompts : zero-shot, few-shot, persona et adversarial qui nous permettent de produire

différents styles d'avis. (Une présentation détaillée de ces prompts est disponible dans l'Annexe 4.2) Nous obtenons donc quatre fichiers principaux :

`GPT_POS.txt` : avis positifs générés par GPT

`GPT_NEG.txt` : avis négatifs générés par GPT

`deepseek_POS.txt` : avis positifs générés par DeepSeek

`deepseek_NEG.txt` : avis négatifs générés par DeepSeek

Avant l'analyse dans TXM, tous les fichiers du corpus ont été tokenisés, une étape nécessaire, car le chinois ne marque pas les frontières entre les mots par des espaces. Nous avons donc utilisé `jieba` (un outil de segmentation lexicale pour le chinois). Nous avons conservé deux versions du corpus :

`corpus_brut` : les commentaires dans leur forme originale ;

`corpus_tokenise` : les mêmes commentaires après segmentation avec jieba.

Les fichiers bruts permettent de garder une trace du texte original, tandis que les fichiers tokenisés servent directement aux analyses statistiques.

3. Analyses Statistiques

Avec les corpus construits, nous allons réaliser plusieurs analyses statistiques avec TXM dans cette partie.

Voici les étapes de notre analyse :

- Nous commençons par vérifier si les différentes parties du corpus se distinguent nettement sur le plan lexical.
- Nous cherchons également à identifier les mots les plus caractéristiques de chaque sous-corpus.
- Nous observons ensuite certains de ces mots dans leur contexte, afin de voir s'ils forment des expressions ou des combinaisons lexicales régulières.
- Enfin, nous analysons les cooccurrences afin de comparer les combinaisons lexicales formées autour du thème de l'hôtel.

3.1. Factorielle des correspondances

Selon la *figure 1*, les trois origines de textes (hum, gpt, deepseek) présentent des profils lexicaux distincts. Nous pouvons constater que les six sous-corpus occupent des positions différentes sur le plan factoriel et on observe notamment que les trois origines de corpus se répartissent de manière assez nette dans des zones différentes du graphique. De plus, les deux premiers axes expliquent ensemble 75,09 % de l'inertie totale, avec 47,04 % pour l'axe 1 et 28,05 % pour l'axe 2.

# ^	Eigenvalue	%	Σ%	
1	0.1323	47.04	47.04	
2	0.0789	28.05	75.09	
3	0.0417	14.83	89.92	
4	0.0206	7.33	97.25	
5	0.0077	2.75	100.00	




Figure 1 - Analyse factorielle des correspondances des six sous-corpus (CA_word)

3.2. Spécificités lexicales

Pour analyser plus précisément les différences lexicales entre les sous-corpus, nous avons extrait avec TXM les 50 mots les plus spécifiques de chaque sous-corpus qui nous permet de garder une liste assez large pour observer les tendances lexicales principales, tout en restant lisible pour l'analyse. (Les 50 mots sont présentés en [Annexe 5.3](#))

Une première observation concerne la ponctuation. Dans les commentaires humains, qu'ils soient positifs ou négatifs, il y a toujours des ponctuations apparaissent : , , . , ; , ! , ? . Cette présence est particulièrement visible dans les avis négatifs humains, où les signes ! et ? accompagnent souvent des jugements forts ou des réactions personnelles. À l'inverse, dans les commentaires générés par IA, la ponctuation apparaît beaucoup moins parmi les mots les plus spécifiques.

Dans les avis positifs humains, les mots spécifiques renvoient souvent à des éléments concrets de l'expérience hôtelière, comme 酒店, 服务, 宾馆, 交通, 地理位置, 价格 ou 早餐. On trouve aussi des évaluations simples et directes, par exemple 不错, 好, 方便 ou 非常. Les avis positifs générés par GPT utilisent davantage un vocabulaire général et évaluatif, avec des mots comme 整体, 体验, 比较, 安静, 自然, 放松, 干净 ou 整洁. Les avis positifs générés par DeepSeek contiennent, quant à eux, plus de détails descriptifs ou sensoriels, comme 床品, 一杯, 亲肤, 香薰, 夜床, 手写 ou 洗衣房. (Traduction est fournie dans [figure 2](#))

Pour les avis négatifs, les commentaires humains se caractérisent par des marques expressives et des jugements directs, comme 差, 不好, 很差, 最差 ou 居然. Ils contiennent aussi des mots liés à des situations concrètes de voyage ou de réservation, par exemple 携程, 机场, 服务员, 预定 ou 招待所. Les avis négatifs générés par GPT sont davantage centrés sur des problèmes matériels ou organisationnels de l'hôtel, avec 浴室, WiFi, 空调, 走廊, 声音, 电视, 遥控器 ou 电梯. Enfin, les avis négatifs générés par DeepSeek font apparaître de nombreux éléments narratifs et concrets, comme 说, 打电话, 拿, 倒, 下去, 浴巾, 水, 泡沫 ou 头发. (Traduction est fournie dans [figure 2](#))

Chinois	Français
酒店, 服务, 宾馆, 交通, 地理位置, 价格, 早餐	hôtel, service, auberge, transport, emplacement géographique, prix, petit-déjeuner
不错, 好, 方便, 非常	pas mal, bien, pratique, très
整体, 体验, 比较, 安静, 自然, 放松, 干净, 整洁	globalement, expérience, relativement, calme, naturel, détendu, propre, bien rangé
床品, 一杯, 亲肤, 香薰, 手工, 洗衣房	literie, un verre, doux pour la peau, banane, fait main, buanderie
差, 不好, 很差, 最差, 居然	mauvais, pas bien, très mauvais, le pire, étonnamment
携程, 机场, 服务员, 预定, 招待所	trip.com , aéroport, serveur, réservation, maison d'hôtes
浴室, 空调, 走廊, 声音, 电视, 遥控器, 电梯	salle de bain, climatisation, couloir, bruit, télé, télécommande, ascenseur
说, 打电话, 拿, 倒, 下去, 浴巾, 水, 泡沫, 头发	parler, téléphoner, prendre, tomber, descendre, serviette, eau, mousse, cheveux

Figure 2 - traduction des mots mentionnés

3.3. Concordances

Pour compléter l'analyse des spécificités lexicales, nous avons observé dans TXM les concordances de certains mots spécifiques. L'objectif est de replacer ces mots dans leur contexte, afin de voir s'ils sont employés de la même manière selon l'origine des commentaires. Après avoir consulté plusieurs concordances, nous avons retenu deux mots-pivots représentatifs : 酒店 (hôtel) pour les avis positifs et 差 (mauvais) pour les avis négatifs. (Les extraits de concordances sont présentés en [Annexe 5.4](#))

Dans les avis positifs humains, les contextes de 酒店 contiennent souvent des informations très concrètes : des dates, des prix, des lieux, des noms ou des détails liés au séjour, comme 60元 (60 RMB), 6月7日 (le 7 juin), 张小姐 (Madame Zhang) etc. On trouve aussi par exemple des références à la réservation, au transport, à la localisation ou à des situations précises vécues par le client, comme 成都 (Province Chengdu), 兰桂坊 (nom de bar) etc. Les commentaires générés par GPT présentent au contraire des structures plus régulières autour de 酒店. On observe des formulations répétées comme 整体 (globalement), 提供 (fournir) ou 这次在...住了... (cette fois à... je suis resté...), qui donnent une impression plus standardisée. Les avis positifs générés par DeepSeek sont plus narratifs : le mot 酒店 apparaît souvent dans des expressions comme 这家酒店 (cet hôtel) ou 一家酒店 (un hôtel), avec des détails descriptifs plus développés, parfois proches d'une scène racontée.

Dans les avis négatifs, les concordances de 差 montrent aussi des différences nettes. Dans les commentaires humains, 差 apparaît souvent avec une ponctuation expressive, comme ! ou ?, et avec des jugements directs. Les contextes sont généralement liés à des problèmes concrets : service, hygiène, équipements, bruit ou transport. Dans les commentaires générés par GPT, 差 apparaît davantage dans des formes similaires : 空气 (air) ...差, 隔音 (insonorisation) 差. Dans les commentaires générés par DeepSeek, il est difficile de les distinguer des commentaires humains, mais nous avons constaté que les occurrences de 差 sont moins nombreuses et apparaissent souvent dans des phrases plus narratives, autour d'une situation ou d'un incident précis.

Un autre point important concerne le degré d'atténuation de la critique dans les textes générés par l'IA. Même dans les avis négatifs, GPT et DeepSeek emploient souvent des formulations moins frontales que les commentaires humains. On trouve par exemple chez

GPT des expressions comme 前台态度不算差 (l'attitude de la réception n'est pas vraiment mauvaise) ou 整体入住流程说不上特别差 (l'ensemble du processus d'arrivée ne peut pas être considéré comme particulièrement mauvais). Chez DeepSeek, on observe aussi des formulations comme 说不上差 (on ne peut pas dire que ce soit mauvais) ou 但绝对不算好 (mais ce n'est absolument pas bon non plus). Ces exemples indiquent que les commentaires générés formulent souvent la critique de manière plus modérée, tandis que les commentaires humains expriment plus directement l'insatisfaction.

3.4. Cooccurrences

Afin de compléter l'analyse des concordances, nous analysons ici les cooccurrences autour du mot 酒店 (hôtel), dans les avis positifs et négatifs. Nous retenons les termes dont la distance moyenne est inférieure ou égale à 4, afin de nous concentrer sur les mots qui apparaissent le plus près du terme-pivot. Plus la distance moyenne est faible, plus le lien entre le terme et 酒店 est proche. (Les extraits de cooccurrences sont présentés en [Annexe 5.5](#))

Dans les avis positifs, les cooccurrences autour de 酒店 ne sont pas les mêmes selon l'origine des commentaires. Dans les commentaires humains, les termes les plus proches renvoient souvent à des informations concrètes sur le type d'hôtel ou sur l'expérience de séjour, comme 经济型 (économique), 连锁 (chaîne), 五星级 (cinq étoiles), 位置 (emplacement), 班车 (navette) ou 地理位置 (localisation). Ces mots montrent que les avis humains décrivent souvent l'hôtel à partir de critères pratiques : catégorie, localisation, transport, prix ou conditions réelles du séjour. À l'inverse, les commentaires générés par GPT présentent des associations plus générales et standardisées, autour de l'apparence, des services et de l'organisation de l'hôtel, avec des termes comme 外观 (apparence), 周围环境 (environnement), 提供 (fournir), 规范 (standardisé), 管理 (gestion), 维护 (entretien) ou 整体 (globalement). Quant à DeepSeek, ses cooccurrences se caractérisent par des détails descriptifs ou narratifs, comme 位于 (situé à), 半山腰 (à mi-hauteur de la montagne), 藏书 (collection de livres), 花园里 (dans le jardin), 停车场 (parking), 设计 (design) ou 建筑 (architecture).

Dans les avis négatifs, les commentaires humains associent 酒店 à des jugements directs et affectifs liés à la catégorie de l'hôtel, en utilisant des termes comme 最烂 (le pire), 最差 (le plus mauvais), 烂 (nul), 经济型 (économique), 五星级 (cinq étoiles), 四星级 (quatre étoiles) ou 三星级 (trois étoiles). Les commentaires générés par GPT sont plutôt centrés sur des défaillances techniques ou fonctionnelles d'espaces spécifiques, tels que 健身房 (salle de sport), 大堂 (hall), 网络 (réseau), 座椅 (sièges), 维护 (entretien), 噪音 (bruit) ou 施工 (travaux). Enfin, DeepSeek adopte à nouveau une approche plus complexe, souvent centrée sur le décalage entre la promesse et la réalité, avec des termes comme 宣称 (prétendre), 自称 (se présenter comme), 宣传 (promotion), 亲子 (parent-enfant), 硬件 (équipements matériels), 市政工程 (travaux municipaux), 托管 (prise en charge) ou 夜间 (nocturne).

4. Bilan des analyses

Les analyses réalisées avec TXM montrent que la distinction entre commentaires humains et commentaires générés par l'IA repose sur plusieurs indices combinés : la ponctuation, le degré de précision des détails, la régularité des formulations, le ton de l'évaluation et la manière de construire le commentaire. Le tableau suivant synthétise les principales caractéristiques observées pour chaque type de commentaire.

Types	Avis positifs	Avis négatifs	Indices_distinction
Humains	Détails concrets liés au séjour : dates, prix, lieux, transport, réservation, localisation. Évaluations simples et directes.	Ponctuation expressive plus fréquente. Jugements directs sur le service, l'hygiène, les équipements, le bruit ou le transport.	Style plus spontané, personnel et parfois irrégulier. Les avis sont souvent ancrés dans une situation vécue.
ChatGPT	Vocabulaire général et positif autour de la qualité globale de l'hôtel : services, équipements, organisation, confort. Formulations régulières comme 整体 ou 提供.	Critiques souvent organisées et atténuées. Associations régulières autour de problèmes typiques : isolation, air, climatisation, attitude du personnel.	Style plus standardisé, organisé et modéré. Présence de structures répétées et d'expressions générales.
DeepSeek	Style plus narratif, avec des détails descriptifs ou sensoriels. Formulations fréquentes autour de 这家酒店 ou 一家酒店.	Occurrences négatives parfois moins nombreuses et critiques moins frontales. Les problèmes sont souvent intégrés dans une scène ou un récit.	Style plus développé et narratif, parfois avec des détails qui donnent une impression de scène construite.

Figure 3 - Synthèse des caractéristiques

5. Annexes

5.1. Statistiques générales du corpus initial

categorie	nb_tokens	tokens_NEG	tokens_POS
共计 / Total	2359952	1108329	1251623
书籍 / Livre	316821	76721	240100
平板 / Pad	279057	167332	111725
手机 / Phone	148828	68812	80016
水果 / Fruit	251198	134659	116539
洗发水 / Shampooing	251429	129993	121436
热水器 / Chauffe-eau	12529	3976	8553
蒙牛 / Marque de lait	53444	24459	28985
衣服 / Vêtement	203469	94693	108776
计算机 / Ordinateur	151962	73446	78516
酒店 / Hôtel	691215	334238	356977

Nombre total de commentaires : 62 773

Nombre total de tokens : 2 359 952

Ces chiffres sont obtenus par [compter.py](#)

5.2. Prompts pour la génération du corpus IA

Cette annexe présente les prompts utilisés pour générer le corpus IA. Les commentaires ont été produits avec deux grands modèles de langage : GPT et DeepSeek V4-Pro. Pour chaque modèle, nous avons généré des avis positifs et des avis négatifs d'hôtels en chinois.

Afin d'obtenir des productions variées, nous avons utilisé quatre stratégies de prompts :

- Zero-shot : Générer des avis à partir d'une consigne simple, sans exemple.
- Few-shot : Fournir de vrais exemples d'avis humains afin d'imiter leur style.
- Persona : Demander au modèle de se mettre dans la peau d'un client d'hôtel.
- Adversarial : Réduire les marques typiques de l'écriture IA et produire des avis plus proches des commentaires humains.

Exemples des Prompts

Type de prompt	POS	NEG
Zero-shot	Générez environ 40 avis positifs d'hôtel en chinois. Chaque avis doit contenir au moins une phrase complète, décrire une expérience de séjour et avoir un style naturel et réaliste. Écrivez un avis par ligne, sans numérotation.	Générez environ 40 avis négatifs d'hôtel en chinois. Chaque avis doit contenir au moins une phrase complète, décrire une expérience de séjour insatisfaisante et avoir un style naturel et réaliste. Écrivez un avis par ligne, sans numérotation.
Few-shot	Voici quelques véritables avis positifs sur des hôtels. Veuillez imiter leur ton et leurs habitudes d'expression afin de générer environ 40 avis positifs. Les points à imiter sont : le rythme des phrases, le niveau de langue plutôt oral, l'usage de la ponctuation, ainsi que la présence éventuelle d'ellipses ou de formulations informelles. Chaque avis doit contenir au moins une phrase complète et décrire une expérience de séjour. Écrivez un avis par ligne, sans numérotation.	Voici quelques véritables avis négatifs sur des hôtels. Veuillez imiter leur ton et leurs habitudes d'expression afin de générer environ 40 avis négatifs. Les points à imiter sont : le rythme des phrases, le niveau de langue plutôt oral, l'usage de la ponctuation, ainsi que la présence éventuelle d'ellipses ou de formulations informelles. Chaque avis doit contenir au moins une phrase complète et décrire une expérience de séjour insatisfaisante. Écrivez un avis par ligne, sans numérotation.
Persona	Imaginez que vous êtes un client ayant récemment séjourné dans un hôtel. Vous devez jouer différents profils de clients et imaginer, selon chaque profil, le contenu et le style des commentaires possibles. Générez 40 avis positifs d'hôtel. Chaque avis doit contenir au moins une phrase complète, être écrit sur une ligne séparée, sans numérotation ni marque de liste. La longueur est libre.	Imaginez que vous êtes un client ayant récemment séjourné dans un hôtel. Vous devez jouer différents profils de clients et imaginer, selon chaque profil, le contenu et le style des commentaires possibles. Générez 40 avis négatifs d'hôtel. Chaque avis doit contenir au moins une phrase complète, être écrit sur une ligne séparée, sans numérotation ni marque de liste. Les avis doivent mentionner des problèmes concrets. La longueur est libre.
Adversarial	Rédigez x avis positifs d'hôtel, de longueurs variées, en imitant les habitudes des véritables utilisateurs et en réduisant les marques typiques de l'IA. Les commentaires peuvent avoir une structure irrégulière, une ponctuation libre, des expressions orales, quelques fautes ou confusions de caractères. Évitez les structures trop régulières du type « description des qualités + recommandation finale » et les expressions trop standardisées comme « globalement », « très bon rapport qualité-prix » ou « fortement recommandé ». Écrivez un avis par ligne, sans numérotation.	Rédigez x avis négatifs d'hôtel, un par ligne, sans numérotation ni explication. Les avis doivent être de longueurs variées, sans introduction ni conclusion systématique, avec une ponctuation libre et des expressions orales. Ils peuvent contenir des fautes, du pinyin, des confusions de caractères ou des informations personnelles hors sujet. Évitez les formulations générales : remplacez-les par des scènes concrètes. Le ton peut être émotionnel, spontané et peu soigné.

Exemples de commentaires fournis à l'IA

Type d'exemple	POS	NEG
long et détaillé	J'ai séjourné dans cet hôtel et c'était plutôt bien. Ce n'était pas aussi mauvais que le laissaient entendre les avis en ligne. J'étais un peu inquiète après avoir lu ces avis, mais il semble que je me sois trompée ! Quelle agréable surprise de voir mon nom affiché sur l'écran dès mon arrivée dans le hall ! Le personnel était très accueillant. Le lit était un peu petit, mais la chambre était très propre et bien rangée, et le service était attentionné. L'emplacement était également idéal, proche du centre-ville, et des bus pour les grottes de Mogao s'arrêtaient juste devant l'hôtel. En résumé, mon voyage à Dunhuang a été très agréable !	Le service était déplorable, dénué de tout professionnalisme ; c'était le pire hôtel trois étoiles que j'aie jamais vu accueillant une clientèle internationale. (Je me demande même comment ils ont pu obtenir une étoile). L'hygiène m'inquiétait beaucoup : la salle du petit-déjeuner grouillait de mouches, les baguettes jetables apportées dans ma chambre étaient sales et leur emballage abîmé, et la zone de commande était extrêmement bruyante, avec des cris en dialecte local. D'après le guide des services, je ne pouvais pas passer d'appels longue distance ; après plusieurs tentatives, j'ai appris que je devais m'enregistrer à la réception. Avant de partir, j'ai demandé à un membre du personnel de m'aider à trouver le numéro de téléphone de la gare routière, mais personne n'a voulu m'aider et tous m'ont ignorée. Heureusement, le seul membre du personnel masculin un tant soit peu aimable a fini par me l'aider à trouver, voyant mon profond mécontentement.
court et oral	Pas mal, je pense revenir la prochaine fois. Les transports sont pratiques et le repas au restaurant était aussi correct.	La chambre n'était pas propre, les équipements étaient vieux, le petit-déjeuner était très mauvais. En plus, il n'y avait plus d'eau froide pendant la douche, j'ai failli me brûler. Je ne reviendrai plus.
mixte avec avis nuancé	L'hôtel est situé tout près de la gare, ce qui est idéal si vous devez prendre le train. En revanche, il est moins pratique pour faire du shopping à Hong Kong, car Tsim Sha Tsui est généralement plus pratique. La chambre standard (avec deux lits) est vraiment petite : les lits ne font que 90 centimètres de large !	C'est l'un des hôtels les plus décevants en termes de rapport qualité-prix que j'aie trouvés à Pékin. Le service était correct, mais les installations laissaient clairement à désirer. Vu le prix, ces problèmes étaient vraiment désagréables. Par exemple, la bonde de la baignoire était bouchée et le réveil sonnait fréquemment en pleine nuit. Si j'avais eu d'autres options, je ne recommanderais pas cet hôtel. Cependant, il est incroyablement populaire, donc je pourrais y retourner, simplement parce qu'il est très proche de mon lieu de voyage, mais mon expérience a été vraiment désagréable !

Remarque : Les prompts et les commentaires ont été rédigés et utilisés en chinois lors de la génération du corpus. Afin de faciliter la compréhension des lecteurs francophones, ils sont présentés ici en traduction française.

5.3. Top 50 des mots spécifiques par sous-corpus

Cette annexe présente les 50 unités lexicales les plus spécifiques obtenues à partir de l'analyse des spécificités dans TXM. Les résultats sont organisés en deux tableaux : Mots_POS pour les avis positifs et Mots_NEG pour les avis négatifs. Dans chaque tableau, les unités sont réparties selon l'origine du texte : commentaires humains, commentaires générés par ChatGPT et commentaires générés par DeepSeek.

Mots_POS

Humain	Chatgpt	Deepseek
,	整体	了
不错	挺	本地
.	很	床品
酒店	体验	里
的	不会	着
好	比较	我
服务	但	不用
宾馆	能	一杯
:	安静	和
不过	。	得
很	自然	满分
日	很快	阿姨
月	晚上	这家
年	过程	治愈
可以	够用	配
总体	顺畅	亲肤
2008	休息	淡淡的
我们	稳定	喝
、	放松	静音
您	没有	放
还是	不算	儿童
下次	还	卡片
感谢您	有点	小
交通	得	夜床
比较	干净	机器人
但是	使用	绝
较	任何	礼宾
环境	状态	手写
地理位置	回来	主动
价格	适合	枕
~	起来	老人
；	整洁	香薰
还会	挺快	厚实
点评	临时	带
免费	这点	送到
方便	轻松	大堂
非常	这里	手工
也	空间	咖啡
上网	行	手绘
最好	干扰	荞麦
品种	挺舒服	。
所以	顺手	送
应该	这次	一本
早餐	出行	香
)	那种	洗衣房
香港	舒适	选
5	复杂	十足
热情	感	每
去	安心	有现
8	方便	感动

Mots_NEG

Humain	Chatgpt	Deepseek
！	明显	了
,	浴室	说
差	有点	我
携程	WiFi	上
？	不太	里
.	一直	着
酒店	不	像
机场	久	没
的	空调	跟前
服务员	发现	台
！	慢	她
2	经常	最后
竟然	轻微	自己
说	结果	被
陈旧	完全	所谓
不要	想着	打电话
最差	不严	洗
3	才	这
是	走廊	把
元	反复	在
4	声音	拿
1	需要	似的
不好	反应	全是
你	无法	一层
这个	一名	坏
给	电视	浴巾
...	旅客	跟
很差	使用	差点
我们	时	那
居然	基本	四十分钟
(	遥控器	撞
一般	几次	倒
这样	松动	根本
实在	影响	水
招待所	门关	下去
他们	稳定	全程
预定	信息	泡沫
)	残留	那个
"	地面	只能
你们	隔壁	一块
以后	觉得	工程部
设施	等	一
、	体验	,
太差	。	毫无
星	晃动	剩
什么	插座	一股
不能	电梯	想
一个	像	吓
脏	椅子	头发
要	几乎	没洗

Extrait de Specificities_word

5.4. Exemples de concordances des mots spécifiques

5.4.1. pos_humain

id, lbn	Left context	Pivot	Right context
GPT_POS_tokenise, 543	很好，使用体验舒适干净。	酒店	管理规范，各项服务安排都很有条理。房间隔音
GPT_POS_tokenise, 548	起来不会有不方便的地方。	酒店	整体维护良好，各项设施看起来都很新。入住
GPT_POS_tokenise, 553	，使用起来都很方便顺手。	酒店	周边环境安静，没有噪音干扰休息。前台服务态度自然亲切
GPT_POS_tokenise, 563	指引电梯位置，体验很贴心。	酒店	整体设计比较现代，公共空间让人感觉很舒服
GPT_POS_tokenise, 567	干净度让人感觉非常放心。	酒店	所在区域很安静，晚上几乎听不到外界声音。浴室
GPT_POS_tokenise, 571	礼貌，交流过程中非常自然。	酒店	提供的饮品补给很及时，体验上很加分。
GPT_POS_tokenise, 577	都合适，睡眠体验很好。	酒店	周边步行范围内餐饮选择很多，非常方便。房间
GPT_POS_tokenise, 583	异味，使用体验整体很不错。	酒店	整体氛围比较安静，适合休息和放松。房间隔热
GPT_POS_tokenise, 588	，使用过程中没有任何不适感。	酒店	整体维护得很好，看起来比较新且干净。入住
GPT_POS_tokenise, 592	采光均匀，不会有阴暗角落。	酒店	电梯运行平稳，上下楼体验很舒适。周边交通
GPT_POS_tokenise, 599	实用风格，居住体验很顺手。	酒店	整体服务稳定可靠，让人感觉很安心。入住
GPT_POS_tokenise, 602	整个过程非常高效几乎不用排队。	酒店	提供电子房卡，直接用手机开门特别方便顺畅。
GPT_POS_tokenise, 608	挂衣和收纳行李都很轻松。	酒店	提供枕头选择服务，不同软硬度睡起来差异明显
GPT_POS_tokenise, 611	设备，整体呼吸感很清爽。	酒店	健身房设备很新，锻炼时感觉空间也很舒适
GPT_POS_tokenise, 616	选择丰富，补充饮料很方便。	酒店	提供行李寄存柜，出行前后都很省心。卫生间
GPT_POS_tokenise, 620	好，睡觉完全不受影响。	酒店	提供深夜简餐服务，晚归也不用担心用餐问题。
GPT_POS_tokenise, 624	接口配置齐全，充电非常便利。	酒店	整体艺术装饰较多，走廊也很有设计感
GPT_POS_tokenise, 627	好，适合短暂停留或阅读。	酒店	提供洗衣快速服务，出差期间非常实用。浴室水压
GPT_POS_tokenise, 631	可靠，对行程安排帮助很大。	酒店	提供环保洗护用品，使用起来感觉很安心。前台
GPT_POS_tokenise, 637	，早出行时特别实用贴心。	酒店	设有安静阅读区，环境非常适合放松阅读。客房灯光
GPT_POS_tokenise, 643	，整个离店过程非常高效省时。	酒店	提供欢迎饮品服务，刚到达时感觉特别有仪式
GPT_POS_tokenise, 647	，对海外旅客非常友好实用。	酒店	提供城市导览二维码，扫码就能获取详细游玩信息
GPT_POS_tokenise, 650	入住时空气更加舒适不干燥。	酒店	提供延时早餐服务，对晚起客人非常贴心友好。
GPT_POS_tokenise, 653	预约专车，出行安排非常顺畅。	酒店	提供环保回收分类系统，整体入住体验更有环保
GPT_POS_tokenise, 656	空气流动感很好很自然。	酒店	设有快速行李配送机器人，科技感和效率都很
GPT_POS_tokenise, 659	灯，夜间办公非常清晰舒适。	酒店	提供儿童用品服务，对家庭入住非常友好周到。入住
GPT_POS_tokenise, 662	，适合不想出门用餐的客人。	酒店	设有商务中心，可以打印文件非常方便。客房窗帘采用双层
GPT_POS_tokenise, 664	双层遮光设计，光线控制非常灵活。	酒店	提供免费城市地图，拿取后出行非常方便实用。前台
GPT_POS_tokenise, 667	连接，无需额外操作很省心。	酒店	提供行李代收服务，提前到达也可以安心寄存。
GPT_POS_tokenise, 670	迷你保险柜，贵重物品存放很安心。	酒店	提供拼车服务推荐，出行选择更加灵活多样。客房配有
GPT_POS_tokenise, 673	协助订购门票，非常适合旅游入住。	酒店	设有安静办公区，适合临时远程工作使用。房间提供
GPT_POS_tokenise, 675	高度选择，睡眠体验更个性化。	酒店	提供快速干洗服务，对商务出行非常实用。浴室
GPT_POS_tokenise, 679	语言频道，娱乐选择很丰富。	酒店	提供专属叫车通道，高峰时段也很方便。整体
GPT_POS_tokenise, 682	也比想象中更干净整洁。	酒店	位置很方便，周边吃饭和出行都很顺畅，

5.4.2. pos_chatgpt

id, lbn	Left context	Pivot	Right context
GPT_POS_tokenise, 543	很好，使用体验舒适干净。	酒店	管理规范，各项服务安排都很有条理。房间隔音
GPT_POS_tokenise, 548	起来不会有不方便的地方。	酒店	整体维护良好，各项设施看起来都很新。入住
GPT_POS_tokenise, 553	，使用起来都很方便顺手。	酒店	周边环境安静，没有噪音干扰休息。前台服务态度自然亲切
GPT_POS_tokenise, 563	指引电梯位置，体验很贴心。	酒店	整体设计比较现代，公共空间让人感觉很舒服
GPT_POS_tokenise, 567	干净度让人感觉非常放心。	酒店	所在区域很安静，晚上几乎听不到外界声音。浴室
GPT_POS_tokenise, 571	礼貌，交流过程中非常自然。	酒店	提供的饮品补给很及时，体验上很加分。
GPT_POS_tokenise, 577	都合适，睡眠体验很好。	酒店	周边步行范围内餐饮选择很多，非常方便。房间
GPT_POS_tokenise, 583	异味，使用体验整体很不错。	酒店	整体氛围比较安静，适合休息和放松。房间隔热
GPT_POS_tokenise, 588	，使用过程中没有任何不适感。	酒店	整体维护得很好，看起来比较新且干净。入住
GPT_POS_tokenise, 592	采光均匀，不会有阴暗角落。	酒店	电梯运行平稳，上下楼体验很舒适。周边交通
GPT_POS_tokenise, 599	实用风格，居住体验很顺手。	酒店	整体服务稳定可靠，让人感觉很安心。入住
GPT_POS_tokenise, 602	整个过程非常高效几乎不用排队。	酒店	提供电子房卡，直接用手机开门特别方便顺畅。
GPT_POS_tokenise, 608	挂衣和收纳行李都很轻松。	酒店	提供枕头选择服务，不同软硬度睡起来差异明显
GPT_POS_tokenise, 611	设备，整体呼吸感很清爽。	酒店	健身房设备很新，锻炼时感觉空间也很舒适
GPT_POS_tokenise, 616	选择丰富，补充饮料很方便。	酒店	提供行李寄存柜，出行前后都很省心。卫生间
GPT_POS_tokenise, 620	好，睡眠觉完全不受影响。	酒店	提供深夜简餐服务，晚归也不用担心用餐问题。
GPT_POS_tokenise, 624	接口配置齐全，充电非常便利。	酒店	整体艺术装饰较多，走廊也很有设计感
GPT_POS_tokenise, 627	好，适合短暂停留或阅读。	酒店	提供洗衣快速服务，出差期间非常实用。浴室水压
GPT_POS_tokenise, 631	可靠，对行程安排帮助很大。	酒店	提供环保洗护用品，使用起来感觉很安心。前台
GPT_POS_tokenise, 637	，早出行时特别实用贴心。	酒店	设有安静阅读区，环境非常适合放松阅读。客房灯光
GPT_POS_tokenise, 643	，整个离店过程非常高效省时。	酒店	提供欢迎饮品服务，刚到达时感觉特别有仪式感
GPT_POS_tokenise, 647	，对海外旅客非常友好实用。	酒店	提供城市导览二维码，扫码就能获取详细游玩信息
GPT_POS_tokenise, 650	入住时空气更加舒适不干燥。	酒店	提供延时早餐服务，对晚起客人非常贴心友好。
GPT_POS_tokenise, 653	预约专车，出行安排非常顺畅。	酒店	提供环保回收分类系统，整体入住体验更有环保
GPT_POS_tokenise, 656	空气流动感很好很自然。	酒店	设有快速行李配送机器人，科技感和效率都很
GPT_POS_tokenise, 659	灯，夜间办公非常清晰舒适。	酒店	提供儿童用品服务，对家庭入住非常友好周到。入住
GPT_POS_tokenise, 662	，适合不想出门用餐的客人。	酒店	设有商务中心，可以打印文件非常方便。客房窗帘采用双层
GPT_POS_tokenise, 664	双层遮光设计，光线控制非常灵活。	酒店	提供免费城市地图，拿取后出行非常方便实用。前台
GPT_POS_tokenise, 667	连接，无需额外操作很省心。	酒店	提供行李代收服务，提前到达也可以安心寄存。
GPT_POS_tokenise, 670	迷你保险柜，贵重物品存放很安心。	酒店	提供拼车服务推荐，出行选择更加灵活多样。客房配有
GPT_POS_tokenise, 673	协助订购门票，非常适合旅游入住。	酒店	设有安静办公区，适合临时远程工作使用。房间提供
GPT_POS_tokenise, 675	高度选择，睡眠体验更个性化。	酒店	提供快速干洗服务，对商务出行非常实用。浴室
GPT_POS_tokenise, 679	语言频道，娱乐选择很丰富。	酒店	提供专属叫车通道，高峰时段也很方便。整体
GPT_POS_tokenise, 682	也比想象中更干净整洁。	酒店	位置很方便，周边吃饭和出行都很顺畅，
GPT_POS_tokenise, 1383	。这次在杭州住了三天，	酒店	位置还算可以，去西湖打车十几分钟，出行不算
GPT_POS_tokenise, 1384	。这次在上海住了两晚，	酒店	离地铁口挺近，走路几分钟就到，拖箱子也
GPT_POS_tokenise, 1385	。这次来成都住了三晚，	酒店	在一条小路上，晚上反而挺安静的，不会
GPT_POS_tokenise, 1386	。这次在西安住了两晚，	酒店	外观看着普通，但进去之后还可以，大堂挺
GPT_POS_tokenise, 1387	，整体感觉还挺轻松的。	酒店	离海边不算远，天气好的时候走过去也
GPT_POS_tokenise, 1388	这次在深圳出差住了三天，	酒店	整体比较现代一点，房间看起来比较清爽。每天打扫
GPT_POS_tokenise, 1389	都可以，整体属于比较实用型的	酒店	。这次去青岛住了三天，酒店位置不错，
GPT_POS_tokenise, 1390	。这次去青岛住了三天，	酒店	位置不错，离海边不远，走路也能过去。
GPT_POS_tokenise, 1391	。这次来广州住了两晚，	酒店	位置挺方便的，地铁出来走一段就到了
GPT_POS_tokenise, 1392	。这次在重庆住了三天，	酒店	在坡上，上下走路稍微有点累，但整体还
GPT_POS_tokenise, 1393	。这次在苏州住了两天，	酒店	整体比较安静，晚上基本没什么噪音。房间布置简单
GPT_POS_tokenise, 1396	。这次在长沙住了两晚，	酒店	位置还可以，离市中心不远。房间进去没有异味
GPT_POS_tokenise, 1397	。这次在合肥住了两晚，	酒店	整体中规中矩，房间干净整洁。空调运行稳定，晚上
GPT_POS_tokenise, 1398	。这次在济南住了三天，	酒店	位置还可以，出门打车方便。房间干净，没有
GPT_POS_tokenise, 1404	。这次在大连住了两晚，	酒店	整体不错，房间干净整齐。晚上比较安静，没有

5.4.3. pos_deepseek

deepseek_POS_tokenise, 1332	看到 餐厅 里 坐满 了 人才 确认 这	酒店	是 满房 状态。那种 窗门 一关 世界 静音 的 体验，
deepseek_POS_tokenise, 1335	一杯 加冰 的 苏打水。在我看来， <u>一家</u>	酒店	是否 用心， 看 它 如何 处理 客人 遗忘 的 物品 就
deepseek_POS_tokenise, 1335	书 留 在 了 房间， 退房 后 接到	酒店	电话， 前台 说 客房部 发现 书里 夹 着 几张 手写 批注
deepseek_POS_tokenise, 1335	着 说 那 他们 会 把 书 放 进	酒店	的书吧 里。健身房 的 饮水机 从 不 缺水， 毛巾架 上
deepseek_POS_tokenise, 1339	的 几 种 树， 第二天 我 走 在	酒店	周围 时， 居然 能 在 那些 陌生 的 街道 上 认 出
deepseek_POS_tokenise, 1340	过客。来 之前 看到 评论 说 <u>这家</u>	酒店	的 早餐 面条 档 阿婆 手艺 一绝， 我排 了 十分 钟 队才
deepseek_POS_tokenise, 1342	， 你 可以 放心 吃。如果 说 大多 数	酒店	的 儿童 俱乐部 只是 把 孩子 们 圈 起来， 那 这家 就是
deepseek_POS_tokenise, 1348	幸运 闯 入 者。我 住 过 的	酒店	里， 这是 第一家 在 大堂 角落 里 设置 了 一 间 小小 的 “
deepseek_POS_tokenise, 1351	” 成为 摆设 的 尴尬， 但 <u>这家</u>	酒店	从 入口 坡道 的 缓度、 电梯 按钮 的 高度、 到
deepseek_POS_tokenise, 1351	动线 测试 过， 我 父母 第一 次 在	酒店	里 行动 自如。我 把 一条 旧 围巾 忘 在 了 大堂
deepseek_POS_tokenise, 1355	， 我 全部 收集 带 回 了 家。	酒店	在 大堂 自助 区 放 了 一 台 鲜榨 果汁 机， 旁边 整齐 码 放
deepseek_POS_tokenise, 1357	的 人。作为 需要 长期 住 在	酒店	的 出差 人员， 最怕 的 就是 客房 服务 的 不一 致 性，
deepseek_POS_tokenise, 1359	翻页 才 发现 世界 变 清 凉 了。	酒店	书吧 的 咖啡 是 免费 提供 给 住客 的， 虽 是
deepseek_POS_tokenise, 1364	在 一 团 晒 暖 的 棉花 上。	酒店	大堂 有 一 面 “ 交换 书架 ”， 客人 可以 留下 一
deepseek_POS_tokenise, 1365	本次 旅行 的 题记。作为 在 <u>这家</u>	酒店	住 了 整整 十四 天 的 长 住客， 我 亲眼 见证 了
deepseek_POS_tokenise, 1365	， 但 他们 会 转 交。我 走出	酒店	大门 时 忽然 有点 鼻 酸， 因为 我 在 陌生 的 城市
deepseek_POS_tokenise, 1366	作为 建筑 系 的 学生， 我 选择 <u>这家</u>	酒店	纯粹 是 因为 它 的 设计 团队 是 我 论文 的 研究 对象
deepseek_POS_tokenise, 1366	离开， 反而 问 我 想 不 想 看	酒店	的 设计 手稿， 五 分钟 后 他 抱 来 了 一 摞 牛皮 纸
deepseek_POS_tokenise, 1367	回家 后 跟 亲戚 们 反复 提起 <u>这家</u>	酒店	， 说 在 那里 她 没有 觉得 自己 老 了 不 方便
deepseek_POS_tokenise, 1369	是 瞬间 痊愈。我要 专门 为 <u>这家</u>	酒店	的 淋浴 系统 写 一段 话。我 住 过 许多 自称 奢华
deepseek_POS_tokenise, 1369	。我 住 过 许多 自称 奢华 的	酒店	， 花洒 要 么 出水 太 分散 像 在 淋 毛 毛 雨， 要 么
deepseek_POS_tokenise, 1369	的 速度 比 我 见 过 的 任何	酒店	都 快， 所以 我 那 几天 干 了 件 奢侈 的
deepseek_POS_tokenise, 1370	常年 需要 飞行 的 投资 人， 我 对	酒店	效率 的 要求 近乎 变态。这 家 酒店 从 办 理 入 住 开始
deepseek_POS_tokenise, 1370	酒店 效率 的 要求 近乎 变态。 <u>这家</u>	酒店	从 办 理 入 住 开始 就 刷新 了 我 的 认知： 前台
deepseek_POS_tokenise, 1371	美术 老师， 我 每天 早上 都 坐 在	酒店	临河 的 露台 上 画 水彩。第二天 我 正 画 着， 餐厅
deepseek_POS_tokenise, 1372	为了 做 一个 小 手术， 术前 在	酒店	住 一 晚。办 理 入 住 时 我 随口 说 了 一 句 明天
deepseek_POS_tokenise, 1373	是 我 那天 唯一 的 安慰。 <u>这家</u>	酒店	的 音响 系统 是 真正 意义 上 的 音响， 不 是 装 在 浴室
deepseek_POS_tokenise, 1375	近乎 修行 的 坚持。我 在 <u>这家</u>	酒店	遗 落 过 一 只 旧 钱包， 里面 现金 不 多 但 有 一 张
deepseek_POS_tokenise, 1375	坐 上 了 离开 的 高铁， 打 电话 给	酒店	后， 客房部 说 打 扫 时 在 床垫 夹 缝 里 找 到 了
deepseek_POS_tokenise, 1376	田野， 沉默 了 很 久。 <u>这家</u>	酒店	的 大堂 没有 用 那种 冷 冰冰 的 大型 水晶 灯， 而是 悬挂
deepseek_POS_tokenise, 1377	残 障 住 客， 我 最 害怕 的 是	酒店	的 “ 无障碍 房 ” 只 是 一个 加 宽 的 门口 和 一个
deepseek_POS_tokenise, 1377	一个 带 扶 手 的 马桶。但 <u>这家</u>	酒店	的 无障碍 设施 让 我 第一 次 感到 被 理解。淋浴 区
deepseek_POS_tokenise, 1378	俯视。我 想 讲 的 是 <u>这家</u>	酒店	一位 门童 的 故事。我 在 入 住 的 第三 天 傍晚，
deepseek_POS_tokenise, 1379	理解 一个 带 娃 家庭 的 慌乱。 <u>这家</u>	酒店	的 亲子 套房 里 有 一个 让 我 太太 差点 哭 出 来

5.4.4. neg_humain

HUM_cat-hotel_pol-NEG_toke	生活多年，从来没有碰到服务这么	差	的，国人的服务难道就这样？感觉自己作为
HUM_cat-hotel_pol-NEG_toke	。房间清洁尚可接受。空调比较	差	房间温度高。电视频道选择比较少。性价比还
HUM_cat-hotel_pol-NEG_toke	很是一般，可以说是有点	差	，就10几年的老装修。还是住潭江半岛酒店
HUM_cat-hotel_pol-NEG_toke	设施老化，淋浴水龙头漏水。隔音	差	，飞机声音响不停。酒店设施非常陈旧，而且接送
HUM_cat-hotel_pol-NEG_toke	希望大家都谨慎一点吧。服务	差	，怎么会有一间酒店没热水呢？我之前
HUM_cat-hotel_pol-NEG_toke	，最后我们决定更换。环境太	差	，非常后悔，再不会去住房间有味道。
HUM_cat-hotel_pol-NEG_toke	，房间小。设施要比以前	差	了，要改进。希望有进步。时常客人来
HUM_cat-hotel_pol-NEG_toke	，不象4星，房间隔音太	差	，隔壁打了一晚麻将，太吵了硬件差：
HUM_cat-hotel_pol-NEG_toke	打了一晚麻将，太吵了硬件	差	：房间设施简单、陈旧，房内有较重的
HUM_cat-hotel_pol-NEG_toke	半夜后中央空调“罢工”。服务	差	：进房发现，床单和被褥就简单地铺在床上
HUM_cat-hotel_pol-NEG_toke	、服务的基本水准）。餐饮	差	：办理入住手续时，总台推荐在酒店用餐（
HUM_cat-hotel_pol-NEG_toke	“小害”了一次！）卫生	差	：这是最要命的一点，在离开酒店后
HUM_cat-hotel_pol-NEG_toke	能听得见唱歌声；3. 厕所	差	，第一个房间因为厕所堵住换另一个房间，结果
HUM_cat-hotel_pol-NEG_toke	酒店会出这种事情；4. 服务态度	差	，给人一种冰冷的感觉。总之，这是
HUM_cat-hotel_pol-NEG_toke	的，一般般吧房间隔音效果超级	差	，晚上竟然能听到外面在搓麻将和讲话声！
HUM_cat-hotel_pol-NEG_toke	酒店不值得推荐。很差，非常	差	。特别是服务员的态度。注意请不要住1
HUM_cat-hotel_pol-NEG_toke	，我想退了。前台服务态度	差	看着地理位置合适才选的这家酒店，酒店没有明显
HUM_cat-hotel_pol-NEG_toke	住的外国人比较多，服务态度就	差	了一点，素质比较低，对于签名还要问你
HUM_cat-hotel_pol-NEG_toke	的贵！！！！！！	差	了俩块钱没早饭！！！！酒店离机场很
HUM_cat-hotel_pol-NEG_toke	去哪儿网上定房前台妹子服务质量超级	差	我去的时候还在跟航空公司的空乘人员吵架
HUM_cat-hotel_pol-NEG_toke	环境一般，设施不好，服务又	差	，就是为了离机场近才选择了这家酒店，以后
HUM_cat-hotel_pol-NEG_toke	硬件设施太一般，服务水准太	差	，除了地理位置还算好，这家酒店乏善可陈一般，没有
HUM_cat-hotel_pol-NEG_toke	钱。对庐山宾馆的印象差差	差	。建议大家还是选择其他宾馆。反正上面有很多
HUM_cat-hotel_pol-NEG_toke	被咬了满脸包，体验非常	差	离机场10分钟车程，酒店设施老久，网速非常慢
HUM_cat-hotel_pol-NEG_toke	月18号的大巴司机服务太	差	，没有报清楚T1还是T2，很多旅客都专门
HUM_cat-hotel_pol-NEG_toke	！交通太不方便了。卫生	差	，有小动物出没。早上第一班车退房人多，
HUM_cat-hotel_pol-NEG_toke	空调机房噪音整个晚上，隔音也	差	！早餐自己买单39元一位，因为没睡好，
HUM_cat-hotel_pol-NEG_toke	朋友订的，听反馈，真心	差	，可惜当时有展会，到处订不到酒店。酒店设施
HUM_cat-hotel_pol-NEG_toke	订不到酒店。酒店设施很差，早饭	差	，要命的服务员态度很差！下次绝对不住！设施
HUM_cat-hotel_pol-NEG_toke	慢。这个酒店的房间也很	差	。酒店的怪味根本无法忍受，设施也不方便，
HUM_cat-hotel_pol-NEG_toke	五星标准。房间那是相当的	差	，不过也是挺便宜的。交通不太方便。
HUM_cat-hotel_pol-NEG_toke	没有，酒店装修老旧，前台服务	差	，不推荐入住。酒店房间设施陈旧，尤其卫生间
HUM_cat-hotel_pol-NEG_toke	蟑螂他挨停车场很近但是酒店隔音	差	床硬各种脏脏的唉...房间真差啊，我住
HUM_cat-hotel_pol-NEG_toke	不信的去了就知道什么是	差	了！！什么是后悔了！！服务人员素质不高

5.4.5. neg_chatgpt

GPT_NEG_tokenise, 113	住客声音很清楚，隐私感很	差	。入住时发现床头灯无法点亮，没有及时修理。
GPT_NEG_tokenise, 149	，和照片差距明显。隔音非常	差	，楼上走路声都听得清清楚楚。床垫塌陷明显
GPT_NEG_tokenise, 209	调节。房间窗户打不开，空气流通非常	差	。浴室洗手台边缘发黑，看起来长期没有清理。入住
GPT_NEG_tokenise, 222	到一半很尴尬。房间空气净化效果	差	，有点闷闷的感觉。停车场指示不清晰，绕
GPT_NEG_tokenise, 239	没有人及时修理。浴室通风效果	差	，湿气很重散不出去。退房时排队时间很长
GPT_NEG_tokenise, 380	盖着不太舒服。房间隔音	差	，隔壁说话声音很清楚。停车场车位紧张，晚上
GPT_NEG_tokenise, 389	迟缓，使用体验很差。房间空气流通	差	，有点闷。前台服务态度比较冷淡，缺乏耐心。
GPT_NEG_tokenise, 459	完全晒干的感觉。房间隔音效果	差	，隔壁说话清楚得很。停车场入口很隐蔽，
GPT_NEG_tokenise, 498	着不太舒服。房间隔音效果	差	，隔壁说话都能听见。停车场指引不清晰，
GPT_NEG_tokenise, 506	需要自己去要。电视遥控器灵敏度	差	，操作不顺畅。房间空气有点沉闷，长时间待
GPT_NEG_tokenise, 549	无法使用部分功能。房间空气循环	差	，长时间待着会觉得闷。浴室水龙头冷热标识
GPT_NEG_tokenise, 576	，像没晒干一样。房间隔音	差	，走廊脚步声非常清晰。停车场入口标识不清楚，
GPT_NEG_tokenise, 655	，影响使用感受。房间隔音非常	差	，楼上走路声很重。停车场没有明确标线，停车
GPT_NEG_tokenise, 703	，经常需要多次按键。房间空气流通	差	，有轻微闷热感。前台服务语气冷淡，缺乏
GPT_NEG_tokenise, 731	用力，不顺滑。前台态度不算	差	，但明显缺乏解决问题的能力。被子有一块明显
GPT_NEG_tokenise, 819	经常需要多次按键。房间空气循环	差	，有轻微异味。前台服务态度比较冷淡，缺乏耐心
GPT_NEG_tokenise, 885	能听清内容，隐私性很	差	。停车场入口标识太小，第一次开车很容易错过。
GPT_NEG_tokenise, 918	有污渍和磨损痕迹。走廊空气流通	差	，有一股长期积存的气味。早餐补货不及时
GPT_NEG_tokenise, 962	，盖起来不太舒服。房间隔音效果	差	，外面声音清晰可听。停车场指示不清楚，
GPT_NEG_tokenise, 1008	反应迟缓，经常失灵。房间空气流通	差	，有轻微闷热感。前台服务态度一般，缺乏耐心
GPT_NEG_tokenise, 1245	还要额外去要。房间空气循环	差	，长时间待着会觉得憋闷。电视遥控器灵敏度很
GPT_NEG_tokenise, 1330	还只能开一条小缝，通风特别	差	。最离谱的是晚上十一点多准备洗澡的时候，
GPT_NEG_tokenise, 1331	原本以为是家连锁酒店，再	差	也不会差到哪里去，结果这次真的刷新了我
GPT_NEG_tokenise, 1335	拍得特别好，实际情况特别	差	。刚到的时候外观看着还可以，但进了电梯
GPT_NEG_tokenise, 1339	的，进来之后才发现细节特别	差	，比如走廊有股说不清的味道，像潮湿又混
GPT_NEG_tokenise, 1356	主动回来的类型，各方面都	差	一点点，但叠加起来就变成明显的不满意这次
GPT_NEG_tokenise, 1375	了入住的时候前台态度其实不算	差	，但效率真的很低，一个简单的入住信息
GPT_NEG_tokenise, 1392	不太友好整体入住流程说不上特别	差	，但就是很多地方不顺畅，小问题叠在
GPT_NEG_tokenise, 1399	一直要调整水温，体验感很	差	房间空气不太好，一进门就有点闷的感觉，
GPT_NEG_tokenise, 1426	断断续续根本睡不踏实房间卫生说不上	差	但也绝对不细致，床头柜下面居然还有上一位
GPT_NEG_tokenise, 1445	残留，没有擦到位，看起来就	差	那么一点点椅子坐下去会轻微晃动，不是很严重
GPT_NEG_tokenise, 1517	澡水都快漫到脚踝了窗帘遮光	差	，早上六点就被亮醒，根本没法睡懒觉空调出风
GPT_NEG_tokenise, 1637	速度慢，用一会儿就积水房间空气流通	差	，待久了会有点闷头电梯等候时间不稳定，

5.4.6. neg_deepseek

deepseek_NEG_tokenise, 646	。前台说我预订姓名和身份证	差	一个字，僵持许久是他们录入错。电视机顶盒
deepseek_NEG_tokenise, 685	客人啊，我要是知道网络这么	差	就换个地方住了，耽误不少事。浴室那个
deepseek_NEG_tokenise, 712	终于能说话了对方态度还很	差	，仿佛我打电话是打扰了她的工作，可是
deepseek_NEG_tokenise, 739	的时候还湿，浴室通风太	差	完全不干，最后穿着湿衬衫去的会议。游泳池
deepseek_NEG_tokenise, 829	几次，崩溃。前台大叔态度特别	差	，我说要个安静的房间他哼了一声
deepseek_NEG_tokenise, 915	非说标配是三条毛巾，我就	差	把行李箱翻个底朝天证明了，最后自己跑去房间
deepseek_NEG_tokenise, 1151	号全靠摸索门牌数字，老年人视力	差	可能直接走错。突发火警铃凌晨响起，所有人
deepseek_NEG_tokenise, 1401	自己流量，但房间里信号也	差	，刷微博都得走到窗边去，住个酒店
deepseek_NEG_tokenise, 1528	站不住脚。房间条件也一般，隔音	差	，走廊声音一清二楚，总之这趟住得非常不愉快
deepseek_NEG_tokenise, 1547	在窥视。整体体验和期望之间	差	了一个湖的距离。电梯要等好久，两台
deepseek_NEG_tokenise, 1559	。前台服务就那样吧，说不上	差	但绝对不算好，问啥都是“哦”
deepseek_NEG_tokenise, 1569	稳定，好起来感觉还行，	差	起来让你怀疑人生。我入住那天碰到的是
deepseek_NEG_tokenise, 1573	没睡着”的默契。刷到	差	评说这酒店前台态度不好，我心想能有多

5.5. Analyse des cooccurrences de termes spécifiques : 酒店 / hôtel

5.5.1. POS

POS_distance

HUM	Distance moyenne	GPT	Distance moyenne	Deepseek	Distance moyenne
该	0,2	外观	0	本身	0,2
经济型	0,2	同价位	0	位于	0,8
连锁	0,3	周围环境	0	半山腰	1
这家	0,5	这家	0,1	顺心	1
班车	1,1	提供	0,4	不像	1,2
五星级	1,3	回	0,5	胃口	1,3
星级	1,4	周边环境	0,5	有心	1,3
粤海	1,5	型	0,5	选	1,4
位置	1,5	位置	0,7	提供	1,4
外部环境	1,7	设有	1,6	藏	1,5
挺不错	1,7	离	1,7	这家	1,5
这个	1,7	规范	1,7	有些	2
派	1,7	配套	1,8	良心	2
花园式	1,8	管理	1,9	必须	2,3
四星级	1,9	周边	1,9	藏书	2,3
一家	2	完善	2	花园里	2,4
五星	2	订	2,1	位置	2,6
此	2	选	2,2	附近	2,6
非常感谢	2	两晚	2,3	一只	2,6
国际	2,2	便利	2,3	停车场	2,8
到达	2,2	实用型	2,3	大门	2,8
专门	2,3	整体	2,4	最好	2,9
地理位置	2,4	有序	2,4	完美	2,9
管理	2,4	维护	2,5	第一次	2,9
最好	2,5	温馨	2,5	免费	2,9
对	2,5	南京	2,7	无障碍	3
选择	2,6	总体	2,8	倍增	3
丹东	2,7	好找	2,8	这	3,1
超值	2,8	步行	2,8	。	3,2
印象	2,8	地铁站	2,9	在	3,3
环境	2,9	两天	3	设计	3,3
大堂	2,9	一家	3	机场	3,3
硬件	2,9	安稳	3	有	3,3
四星	3	交通	3,2	真心	3,3
这回	3	市中心	3,2	不错	3,4
最高	3	三天	3,3	一家	3,4
从	3	很多	3,4	老	3,4
感谢您	3,1	。	3,4	凌晨	3,4
算是	3,2	各项	3,4	住	3,5
入住	3,2	不远	3,5	自行车	3,5
附近	3,2	指引	3,5	赞	3,5
的	3,3	属于	3,5	建筑	3,5

5.5.2. NEG

NEG_Distance

HUM	Distance moyenne	GPT	Distance moyenne	Deepseek	Distance moyenne
经济型	0	外观	0	住个	0
该	0,5	健身房	0	位于	0
这家	0,9	这	0,4	宣称	0
五星级	0,9	公共	0,4	这家	0,2
四星级	0,9	这家	0,5	内部	0,2
航空	1	整体	0,6	自称	0,6
最烂	1,1	者	1	宣传	0,9
这个	1,2	大堂	1,5	亲子	1
星级	1,2	网络	1,6	wifi	1
此	1,4	区域	1,8	硬件	1
三星级	1,5	到	1,8	号称	1,2
管理	1,7	座椅	2	没住	1,5
住进	1,8	教练	2	市政工程	1,5
位置	1,8	打印	2	友好	2
连锁	1,9	但	2,3	菜市场	2
烂	2	附近	2,3	按摩师	2
居住	2	维护	2,5	托管	2
合作	2,1	当天	2,5	夜间	2
最差	2,1	爱好者	2,5	提供	2,2
经济	2,2	凌晨	2,7	建筑	2,3
外观	2,3	健身	3	这	2,4
这种	2,3	周边	3	书吧	2,5
老	2,4	本来	3	外墙	2,5
一家	2,5	发现	3,1	五星	2,5
五星	2,7	噪音	3,2	这下	2,5
选	2,7	位置	3,2	。	2,6
内部	2,8	大厅	3,3	餐盘	2,7
同	2,8	较长	3,5	安全感	2,8
做法	2,8	sb	3,7	不是	2,9
坑	2,9	施工	3,8	SPA	3
到达	2,9	频繁	3,8	星空	3
写字楼	3	没有	3,9	对	3,2
慎重	3	自驾	4	海滩	3,3
四星	3	到位	4	而	3,3